

ABSTRACT

Aquest projecte presenta una anàlisi exploratòria de dades hospitalàries sintètiques amb l'objectiu d'identificar factors clínics, demogràfics i operatius associats als costos sanitaris. L'estudi integra dues fonts de dades —informació clínica de pacients i operativa hospitalària— que, després d'un procés de neteja, transformació i fusió, donen lloc a un únic *dataset* de 1.000 registres i 32 variables.

L'anàlisi inclou estadística descriptiva, exploració de relacions entre variables, proves d'hipòtesis (t-test i Chi-quadrat) i correlacions no paramètriques (Spearman), així com processament de text no estructurat per extreure informació rellevant de les prescripcions mèdiques. També es realitza una anàlisi temporal, financera i operativa per entendre patrons d'hospitalització, recurrència de pacients i distribució de tractaments i medicació.

Els resultats mostren una relació molt feble entre la majoria de variables i el cost total hospitalari. Només l'edat i el diagnòstic presenten diferències estadísticament significatives en relació amb els costos. S'identifiquen patrons clínics rellevants, com una major prevalença de malalties cròniques en edats avançades, una disminució general de casos el 2023 i un augment progressiu en la prescripció de medicació relacionada amb la salut mental. També s'observen diferències en la reincidència de pacients segons l'hospital.

La principal limitació de l'estudi és la naturalesa sintètica del conjunt de dades, que redueix la variabilitat i la representativitat respecte a dades clíniques reals. Malgrat això, el treball demostra un procés metodològic complet i estableix una base sòlida per a futures investigacions, incloent l'aplicació de models de Machine Learning i tècniques avançades de processament del llenguatge natural en dades sanitàries reals.

INTRODUCCIÓ

DEFINICIÓ DEL PROBLEMA I OBJECTIUS

En l'actualitat, l'evolució de l'atenció mèdica i la millora dels resultats clínics depenen directament de l'anàlisi de dades. En els models de salut actuals, aquest flux informatiu constant ofereix una visió estratègica per a una presa de decisions més precisa. Paral·lelament, els centres hospitalaris han de gestionar la pressió creixent d'optimitzar el flux de pacients sense sacrificar la qualitat assistencial; un equilibri complex que implica coordinar urgències i activitat programada, gestionar les limitacions de capacitat i ajustar els torns del personal per millorar l'experiència del pacient.

L'ús de conjunts de dades que integren informació operacional i clínica permet transformar la gestió hospitalària, ja que és possible predir quins perfils requeriran una atenció de cost elevat, anticipar els volums d'afluència diaris o mensuals i detectar colls d'ampolla en els temps d'espera. En darrera instància, aquesta intel·ligència de dades facilita una planificació de plantilles molt més eficient, adaptada als patrons horaris i a les necessitats reals del servei.

Propòsit de l'anàlisi: Per què s'analitza aquest conjunt de dades?

L'objectiu principal d'aquest projecte és analitzar un conjunt de dades hospitalàries per identificar patrons entre pacients, tractaments i costos mèdics. Concretament, es busca determinar quines variables influeixen de manera més significativa en el cost total de l'atenció sanitària per pacient (*Total Bill*).

Per assolir aquest objectiu, s'estudien tant variables demogràfiques —com l'edat i el gènere— com variables clíniques —com el diagnòstic i el tractament rebut— amb la finalitat d'entendre la seva influència en el cost associat a l'estada hospitalària de cada pacient.

Preguntes clau o "insights": Què volem analitzar, entendre, identificar o descobrir? Davant qualsevol conjunt de dades poden sorgir múltiples línies d'anàlisi. En aquest estudi, però, l'objectiu principal és identificar i comprendre quines variables estan relacionades amb els costos hospitalaris. Per abordar aquesta qüestió, estructurem l'anàlisi a partir d'un conjunt de preguntes clau, organitzades per blocs temàtics, que ens permetran explorar el problema de manera sistemàtica i orientada a l'obtenció d'*insights* rellevants.

1. Estadística descriptiva

- Quina es la distribució de pacients per gènere, edat, diagnòstics o tractament?
- Quina és la distribució de pacients entre hospitals?
- Quina es la distribució de tractaments per hospital? Hi ha d'específics?
- Quina és la distribució de l'edat/edat mitjana dels pacients per condició mèdica?
- Hi ha diferències entre gèneres o edats en la freqüència de diagnòstics?
- Quina és la reincidència de pacients per hospital?
- Quins pacients visiten més un número més gran d'hospitals?
- Hi ha alguna relació entre el cost sanitari dels pacients i la seva edat o la taxa de recuperació de la malaltia?

2. Anàlisi temporal

- Quina és la durada mitjana d'una estada hospitalària per gènere o per edat en funció dels anys, mesos o dies de la setmana?
- Quin és el nombre d'hospitalitzacions en funció del gènere per malaltia en relació a una variable temporal?
- Quina és la reincidència d'hospitalitzacions per pacient?

4. Anàlisi financer

- Quins diagnòstics estan associades amb costos més elevats?
- Quins metges estan associats amb les facturacions més altes? o més baixes?
- Quina és la freqüència de facturació per gènere o edat?
- Quins són els hospitals amb més pacients o amb cost de facturació més alt? i més baix?
- Quina és la variabilitat del cost en funció dels dies d'estada?

5. Anàlisi operatiu hospitalari

- Quina relació hi ha entre la durada de l'estada o el número d'habitació i el cost del tractament?
- Quins medicaments es fan servir més freqüentment per condició mèdica?

Tot i que l'anàlisi es va iniciar a partir d'aquest conjunt de preguntes inicials, el procés exploratori de les dades va donar lloc a nous interrogants i línies d'investigació addicionals. A mesura que es van identificar patrons, anomalies i relacions inesperades entre variables, van sorgir noves preguntes que van permetre aprofundir encara més en la comprensió dels factors associats als costos hospitalaris i al comportament clínic dels pacients.

Context del *dataset*: Qui el va recollir? Com es va obtenir?

Inicialment, es pretenia treballar amb dades clíniques reals; tanmateix, les restriccions d'accés a aquest tipus d'informació van fer necessari utilitzar finalment un conjunt de dades sintètic procedent de Kaggle (www.kaggle.com), assumint les limitacions que això comporta. Aquest dataset s'ha emprat exclusivament amb finalitats educatives i d'anàlisi, i no inclou cap dada real de pacients.

Es van utilitzar dos conjunts de dades: un amb informació clínica dels pacients i un altre amb informació operativa dels hospitals. Després de realitzar la neteja i la transformació de les dades, aquests conjunts es van integrar en un únic dataset, que es va emprar per dur a terme l'anàlisi amb finalitats educatives.

METODOLOGIA

EXPLORACIÓ INICIAL DE LES DADES A ANALITZAR

Descripció del HealthcareDataset1: Nombre de registres, columnes, tipus de variables. El primer conjunt de dades conté informació clínica dels pacients i compta amb 1000 registres i 11 camps, sent TotalBill la variable objectiu principal de l'anàlisi, i *Full Prescriptions Details* la variable no estructurada escollida per fer processament de text.

Categòriques	Numèriques	DateTime	No estructurada	No Rellevants
				PatientID
				PatientName
	Age (discreta)			
Gender				
BoodType				
Diagnosis				
Treatment				
		AdmissionDate		
		Discharge Date		
	TotalBill (continua)			
			Full Prescription Details	

Descripció del HealthcareDataset2: Nombre de registres, columnes, tipus de variables. El segon conjunt de dades conté informació operativa dels hospitals i també compta amb 1000 registres i només 7 camps, sent TotalBill la variable objectiu principal de l'anàlisi, i *Full Prescriptions Details* la variable no estructurada escollida per fer processament de text.

Categòriques	Numèriques	No Rellevants
		PatientID
Hospital		
DoctorName		
	RoomNumber (discreta)	
	DailyCost (continua)	
TreatmentType		
	RecoveryRating (discreta)	

El més important a l'hora d'analitzar qualsevol tipus de dades és entendre-les abans de començar el seu processament. Amb la finalitat de facilitar aquesta comprensió, s'ha elaborat el següent diccionari de dades.

Diccionari de dades: Definicions de cada camp i número de valors únics

- **PatientID** (ID): identificador únic del pacient. Hi ha 1000 registres únics
- **PatientName** (Nom): Noms dels pacients ingressats a l'hospital i associat amb la història clínica. Informació poc rellevant. Alguns s'han visitat a més d'un hospital.
- **Age** (Edat): Edat dels pacients en el moment de l'ingrés, s'expressa entre 0 i 99 anys.
- **Gender** (Sexe): Gènere dels pacients, es treballarà amb 3 "Male" (masculí), "Female" (femení) i "Other" (altres).
- **BloodType** (Tipus de Sang): Tipus de sang dels pacients, que pot ser un dels tipus de sang més comuns. Hi ha 8 valors diferents ("A(±)", "B(±)", "AB(±)" i "O(±)") i durant el processament s'agruparan en 4 valors únics per Rh (o factor Rhesus) molt important clínicament i menys rellevant en l'anàlisi de dades.
- **Diagnosis** (Diagnòstic): Descripció de la condició mèdica/diagnòstic pel qual el pacient és admès, és a dir, especifica l'afecció mèdica primària o el diagnòstic associat amb el pacient. En aquest cas tenim els següents 5 valors únics "Grip", "Covid-19", "Hipertensió", "Diabetis" i "Asma".
- **Treatment** (Tractament): Conjunt d'intervencions mèdiques aplicades a un pacient per tractar o gestionar una malaltia, condició o lesió. Inclou 3 valors únics i són: "Medication" (medicaments), "Therapy" (teràpies no farmacològiques com fisioteràpia, teràpia psicològica, rehabilitació, etc.) o "Surgery" (procediments quirúrgics).
- **AdmissionDate** (Data d'ingrés/alta): Data en què el pacient va ingressar a l'hospital.
- **Discharge Date** (Data d'alta): La data en què el pacient va ser donat d'alta del centre d'atenció mèdica. Durnat el processament, a partir d'aquesta data i l'anterior calcularem els dies d'estada hospitalària (DoS o *Days of Stay*).
- **TotalBill** (cost): cost total resultant del tractament del pacient pels serveis mèdics rebuts durant l'estada a l'hospital. Aquesta variable numèrica s'expressa com un valor flotant.
- **Full Prescription Details** (Medicació): Llista de medicaments receptats o administrats al pacient durant la seva hospitalització. Alguns exemples són "Furosemide", "Ibuprofen", "Fluoxetine", "Amoxicillin" i "Lipitor". Servirà per fer processament de text no estructurat
- **Hospital** (Hospital): Nom o identificador de l'hospital on es troba ingressat el pacient. Són 5 valors únics "Cedar Sinai Clinic", "Green Valley Medical Center", "Maple Grove Health Facility", "Riverside Hospital" i "Silver Oak Medical Plaza".
- **Doctor** (Metge): Nom o identificador del metge responsable de l'atenció del pacient. Hi ha 369 valors únics i alguns treballen a més d'un hospital.

- **Room number** (Habitació): Identificador de l'habitació on s'allotja el pacient.
- **DailyCost** (Cost diari): Cost hospitalari total associat a un dia incloent despeses com medicaments, salaris, procediments, estada i altres serveis mèdics. Aquesta variable numèrica s'expressa com un valor flotant.
- **TreatmentType** (Tipus de tractament): Conjunt d'intervencions mèdiques aplicades per tractar o gestionar una malaltia, condició o lesió. En la història clínica del pacient en teníem 3, i en el àmbit hospitalari tenim 4 perquè diferencia "Therapy" en Physical *Therapy*" (teràpies no farmacològiques com fisioteràpia, rehabilitació, etc.) de "Counseling" (teràpia psicològica). A més inclou "*Medication*" (medicaments) i "*Surgery*" (procediments quirúrgics).
- **RecoveryRating** (Taxa de recuperació): Variable que mesura el grau de recuperació d'un pacient després d'un tractament o ingrés hospitalari. Generalment s'expressa en una escala numèrica o categòrica que indica la completitud o efectivitat de la recuperació, on valors més alts representen una millor recuperació. Normalment pren valors discrets entre 1-10 on tenim una recuperació molt baixa (1-2), baixa (3-4), moderada (5-6), bona (7-8) i excel·lent o completa (9-10)

Totes les variables categòriques són polítòmiques, és a dir, poden prendre més de dos valors. Per simplificar l'anàlisi durant el processament, es transformaran en variables dicotòmiques, com l'Rh, i variables polítòmiques amb valors entre 3 i 5 categories, segons el cas.

NETEJA I TRANSFORMACIÓ DE DADES

Maneig de duplicats i dades faltants

Els valors duplicats s'han de revisar i eliminar quan apareixen en el conjunt de dades, ja que poden distorsionar els resultats de l'anàlisi i inflar artificialment les mesures estadístiques. No es van observar valors duplicats ni en el conjunt de dades de pacients (informació clínica-HealthcareDataset1) ni en el de hospitals (informació operativa-HealthcareDataset2).

Els valors faltants es poden eliminar quan representen un percentatge petit del conjunt de dades (3-5%) i no afecten variables clau, però cal tenir precaució perquè l'eliminació massiva pot reduir la mostra i introduir biaix.

Quan els valors faltants són abundants o corresponen a variables importants, és preferible utilitzar tècniques d'imputació, com substituir-los per la mitjana, mediana, moda, o altres mètodes avançats, o crear una categoria especial que indiqui la seva absència.

En el cas dels pacients, el percentatge de valors faltants en el conjunt de dades arribava al 6% i afectava una variable clau com es el cost (*TotalBill*). Per aquest motiu, aquests valors es van imputar utilitzant la mitjana de l'agrupació per diagnosi i tractament.

En el cas dels hospitals, els valors faltants eren encara més alts, 7,8%, però afectaven una variable menys rellevant, Hospital, la qual cosa minimitza l'impacte sobre l'anàlisi.

<pre>1 patients.info() ✓ 0.0s <class 'pandas.core.frame.DataFrame'> RangeIndex: 1000 entries, 0 to 999 Data columns (total 11 columns): # Column Non-Null Count Dtype --- - 0 PatientID 1000 non-null int64 1 PatientName 940 non-null object 2 Age 1000 non-null int64 3 Gender 1000 non-null object 4 BloodType 1000 non-null object 5 Diagnosis 1000 non-null object 6 Treatment 1000 non-null object 7 AdmissionDate 1000 non-null datetime64[ns] 8 DischargeDate 1000 non-null datetime64[ns] 9 TotalBill 940 non-null float64 10 Full Prescription Details 1000 non-null object dtypes: datetime64[ns](2), float64(1), int64(2), object(6) memory usage: 86.1+ KB</pre>	<pre>1 hospitals.info() ✓ 0.1s <class 'pandas.core.frame.DataFrame'> RangeIndex: 1000 entries, 0 to 999 Data columns (total 7 columns): # Column Non-Null Count Dtype --- - 0 PatientID 1000 non-null int64 1 Hospital 922 non-null object 2 DoctorName 1000 non-null object 3 RoomNumber 1000 non-null int64 4 DailyCost 1000 non-null float64 5 TreatmentType 1000 non-null object 6 RecoveryRating 1000 non-null float64 dtypes: float64(2), int64(2), object(3) memory usage: 54.8+ KB</pre>
--	---

Registres de dates inconsistents

Durant la fase de neteja de dades, es van realitzar diverses comprovacions per garantir la qualitat del conjunt de dades. Es va verificar que no hi haguessin formats de data invàlids i es va controlar la inconsistència lògica de les dates, assegurant que la data d'alta no fos anterior a la data d'ingrés.

També es va comprovar que no hi havia valors negatius en las variables numèriques *TotalBill* i *DailyCost*, cosa que significaria valors nnòmals

Distribució de freqüència de variables


S'observa que el conjunt de dades utilitzat presenta freqüències molt similars en totes les variables, tant pel que fa als pacients com als hospitals.

Aquest fet posa de manifest les seves limitacions, ja que es tracta d'un conjunt de dades altament sintètic, generat artificialment, que no reflecteix amb precisió la complexitat ni la variabilitat pròpies de les dades clíniques reals. Aquesta característica redueix de manera significativa l'abast de les anàlisis possibles, atès que no s'hi observen patrons ni relacions típiques de contextos reals.


HEALTHCARE DATA ANALYSIS

Anàlisi de dades exploratòries i Processament de text no estructurat

Frequency Distribution of Patients Data



Frequency Distribution of Hospital Data




Identificació de *outliers*.

Els valors extrems (*outliers*) s'han de tenir en compte durant l'anàlisi de dades, ja que poden influir de manera significativa en els resultats estadístics i en els models analítics. Aquests valors poden correspondre a errors de registre o mesura, però també poden representar casos reals poc freqüents però rellevants. Per aquest motiu, és important identificar-los, analitzar-ne l'origen i decidir, de manera justificada, si s'han de corregir, transformar o mantenir dins del conjunt de dades. Els nostres *datasets* son tan sintètics que no contenen *outliers*.

HEALTHCARE DATA ANALYSIS

Anàlisi de dades exploratòries i Processament de text no estructurat



Transformació de les variables

A partir de les dues variables temporals es va crear una nova variable anomenada dies d'estància hospitalària (*DoS, Days of Stay*). De manera sorprenent, es va comprovar que tots els valors eren iguals a 1; per tant, aquesta variable és una **variable constant** i no aporta *informació rellevant per a l'anàlisi*.

A continuació, es van crear vuit noves variables categòriques a partir de les dates d'admissió (*AdmissionDate*) i d'alta (*DischargeDate*) per tal de dur a terme anàlisis temporals de les dades. Aquestes variables tenien en compte diferents unitats de temps: l'any (*AD_Year* i *DD_Year*), el trimestre (*AD_Quarter* i *DD_Quarter*), el mes (*AD_Month* i *DD_Month*) i el dia (*AD_Day* i *DD_Day*).

Mitjançant el processament de text no estructurat, es va extreure la informació de la prescripció facultativa del pacient (*Full Prescription Details*) i es va organitzar en columnes independents, de manera que a cada columna hi correspon una medicació i la seva dosi. Per a un mateix pacient, la mateixa medicació no es repeteix en dues

HEALTHCARE DATA ANALYSIS

Anàlisi de dades exploratòries i Processament de text no estructurat

columnes, i el nombre màxim de medicacions administrades per pacient en un ingrés és de quatre medicaments diferents. Aquesta organització incrementa el nombre de variables en quatre variables categòriques més.

Finalment, es van agrupar els grups sanguinis segons el factor Rh i es va crear una nova variable categòrica dicotòmica, anomenada Rh, que indica si és positiu o negatiu.

Un cop acabada la neteja i transformació de variables es va crear un únic *dataset* amb 1000 registres i 32 variables, a partir dels dos inicials, per tal de continuar amb l'anàlisi exploratòria. Mantenim 60 valors faltants de PatientName, 78 de Hospital i en Medicine3 i Medicine4 apareixen valors faltants que implica que hi ha pacients amb només dos tractaments i 674 amb tres o 357 amb quatre medicaments en els seus detalls de prescripció.

Un cop finalitzades les tasques de neteja i transformació de variables, es va generar un únic conjunt de dades amb 1.000 registres i 32 variables, integrant la informació procedent dels dos datasets inicials, amb l'objectiu de continuar amb l'anàlisi exploratòria. Es van mantenir 60 valors faltants a la variable *PatientName* i 78 a *Hospital*. Pel que fa a les variables *Medicine3* i *Medicine4*, la presència de valors faltants indica que no tots els pacients van rebre el mateix nombre de medicaments: tots van rebre al menys dos, 674 en van rebre tres i 357 en van rebre quatre segons els detalls de prescripció.

```
1 df = (
2     patients
3     .merge(
4         hospitals,
5         on="PatientID",
6     )
7 )
8 df.info()
✓ 0.0s

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 32 columns):
#   Column              Non-Null Count  Dtype
---  -
0   PatientID           1000 non-null  int64
1   PatientName         940 non-null   object
2   Age                 1000 non-null  int64
3   Gender              1000 non-null  object
4   BloodType           1000 non-null  object
5   Diagnosis            1000 non-null  object
6   Treatment            1000 non-null  object
7   AdmissionDate        1000 non-null  datetime64[ns]
8   DischargeDate        1000 non-null  datetime64[ns]
9   TotalBill           1000 non-null  float64
10  Full Prescription Details 1000 non-null  object
11  DoS                  1000 non-null  int64
12  AD_Month             1000 non-null  category
13  AD_Day               1000 non-null  category
14  AD_Quarter           1000 non-null  category
15  AD_Year              1000 non-null  category
16  DD_Month             1000 non-null  category
17  DD_Day               1000 non-null  category
18  DD_Quarter           1000 non-null  category
19  DD_Year              1000 non-null  category
...
30  TreatmentType        1000 non-null  object
31  RecoveryRating       1000 non-null  float64
dtypes: category(8), datetime64[ns](2), float64(4), int64(4), object(14)
memory usage: 197.2+ KB
```

```
1 df.isnull().sum()
✓ 0.0s


PatientID           0
PatientName         60
Age                 0
Gender              0
BloodType           0
Diagnosis            0
Treatment            0
AdmissionDate        0
DischargeDate        0
TotalBill           0
Full Prescription Details 0
DoS                  0
AD_Month             0
AD_Day               0
AD_Quarter           0
AD_Year              0
DD_Month             0
DD_Day               0
DD_Quarter           0
DD_Year              0
Medicine1            0
Medicine2            0
Medicine3            326
Medicine4            643
RhFactor             0
...
RoomNumber           0
DailyCost            0
TreatmentType        0
RecoveryRating       0
dtype: int64
```

ANÀLISI EXPLORATÒRIA DE DADES (EDA)

Estadístiques descriptives i distribució de les variables numèriques


Quan analitzem la estadístiques descriptives del *dataset* veiem que promig (mean) y mitjana (50%) estan bastant pròximes. Amb aquests valors de promig i suposaríem una distribució normal, però quan analitzarem la distribució. veiem que no es normal.

	PatientID	Age	TotalBill	RoomNumber	DailyCost	RecoveryRating	DoS
count	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000	1000.0
mean	500.500000	50.500000	10040.947498	249.799000	998.358349	5.436009	1.0
std	288.819436	28.599859	5626.658910	144.568927	545.178933	2.776767	0.0
min	1.000000	0.000000	200.928022	1.000000	52.023698	1.000000	1.0
25%	250.750000	26.000000	5326.999625	125.000000	527.573516	3.000000	1.0
50%	500.500000	51.500000	10202.339277	251.500000	977.376355	5.436009	1.0
75%	750.250000	75.000000	14552.941322	375.000000	1459.068550	8.000000	1.0
max	1000.000000	99.000000	19979.201527	499.000000	1994.047594	10.000000	1.0




Relacions entre variables numèriques

No s'observa cap relació significativa entre les variables numèriques, ni tan sols entre *DailyCost* i *TotalBill*, tal com es mostra a la gràfica següent.




Relacions entre variables numèriques i categòriques

De manera similar al cas anterior, no s'observa cap relació entre les variables numèriques i les categòriques, com **Treatment** o **Diagnosis**, tal com mostren les dues figures següents.

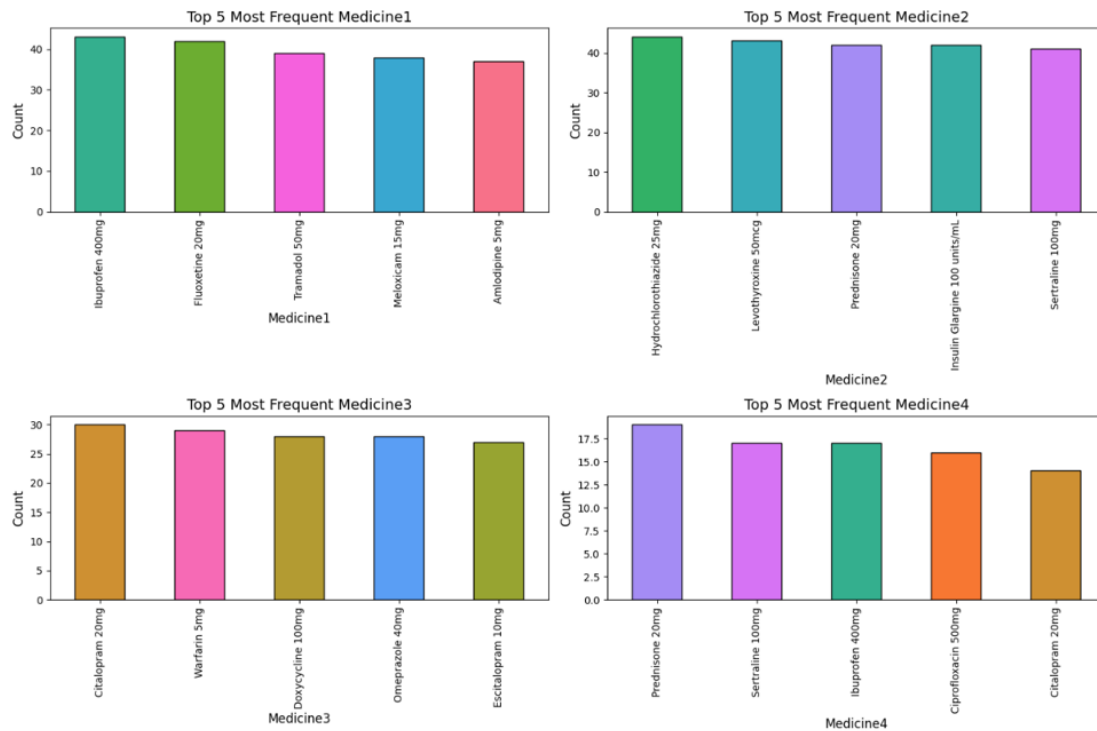


També s'han representat els costos en funció de les diferents variables categòriques mitjançant violín i boxplot i els resultats són molt similars en tots els casos probablement degut al caràcter sintètic del data set



Distribució de les noves variables categòriques

Quan analitzem les variables categòriques que fan referència al medicament prescrit observem que no hi ha una prescripció predominant en cap de les quatre categories. No obstant això, en la figura següent s'ha representat la distribució dels 5 medicaments més prescrits per cadascuna de les categories obtingudes després del processament de text.




IDENTIFICACIÓ DE PATRONS I ANÀLISI DE VARIABLES

Correlacions entre variables quantitatives

La matriu de correlació utilitzada és la de Spearman, ja que les variables no segueixen una distribució normal i, per tant, no és adequat aplicar la correlació de Pearson, que assumeix normalitat.

En general, les correlacions entre les variables quantitatives són molt febles. La correlació més alta observada és entre DailyCost i Age, però és només de 0,035, cosa que indica una relació pràcticament inexistent, tal com es mostra a la figura següent.



Anàlisi estadística entre variables numèriques (t-test)

El t-test és una prova estadística que s'utilitza per comparar les mitjanes de dos grups i determinar si la diferència observada entre elles és estadísticament significativa o si podria haver-se produït per atzar.

En aquest cas, s'aplica per comparar la mitjana del cost (*TotalBill*) entre dos grups de pacients definits segons el valor d'una altra variable quantitativa, com ara *Age*, *DailyCost* o *RecoveryRating*, dividida en valors per sota o per sobre del valor promig. D'aquesta manera, el test permet avaluar si cadascuna d'aquestes variables quantitatives està associada amb diferències en el cost total.

La hipòtesi nul·la (H_0) estableix que els dos promigs són iguals, mentre que la hipòtesi alternativa (H_1) planteja que són diferents. Quan el valor p és inferior a 0,05, es conclou que hi ha una diferència estadísticament significativa entre els dos grups. El resultat d'aplicar el t-test. Només l'edat mostra una diferencia significativa de cost entre els pacients que estan per sobre i per sota del valor promig (50). Els resultats son idèntics per la mediana (52).

```
Division variable: Age
T-statistic: -2.280, p-value: 0.023
→ There is a statistically significant difference in 'TotalBill' between the two groups based on the median of the variable.

Division variable: DailyCost
T-statistic: -0.828, p-value: 0.408
→ No significant difference in 'TotalBill' between the groups based on the median of the variable.

Division variable: RecoveryRating
T-statistic: -0.147, p-value: 0.883
→ No significant difference in 'TotalBill' between the groups based on the median of the variable.
```

```
Division variable: Age
T-statistic: -2.221, p-value: 0.027
→ There is a statistically significant difference in 'TotalBill' between the two groups based on the mean of the variable.

Division variable: DailyCost
T-statistic: -0.918, p-value: 0.359
→ No significant difference in 'TotalBill' between the groups based on the mean of the variable.

Division variable: RecoveryRating
T-statistic: -0.147, p-value: 0.883
→ No significant difference in 'TotalBill' between the groups based on the mean of the variable.
```

Anàlisi estadística entre variables categòriques (Chi²)

El test Chi-quadrat (χ^2) és una prova estadística que s'utilitza per analitzar si existeix una relació significativa entre dues variables categòriques. En aquest cas, s'aplica per avaluar si el cost total (*TotalBill*) està associat amb diferents variables categòriques com ara *Gender*, *Diagnosis*, *Treatment*, *Hospital*, *DoctorName* o els diferents medicaments administrats (*Medicine1*, *Medicine2*, *Medicine3* o *Medicine4*). El test compara la distribució observada dels casos amb la que s'esperaria si no hi hagués cap relació entre les variables.

La hipòtesi nul·la (H_0) estableix que les variables són independents, mentre que la hipòtesi alternativa (H_1) indica que existeix una associació entre elles. Quan el valor p és inferior a 0,05, es conclou que hi ha una relació estadísticament significativa entre la variable categòrica analitzada i el cost total. En aquest cas només s'ha trobat una relació estadísticament significativa amb Diagnosis (tractament).

```
Variable: Gender
Chi2: 1915.7667, p-value: 0.4330
→ No significant relationship with TotalBill

Variable: BloodType
Chi2: 2860.0548, p-value: 0.4909
→ No significant relationship with TotalBill

Variable: Diagnosis
Chi2: 4000.0000, p-value: 0.0167
→ There is a significant relationship with TotalBill

Variable: Treatment
Chi2: 2000.0000, p-value: 0.0657
→ No significant relationship with TotalBill

Variable: Hospital
Chi2: 3527.6197, p-value: 0.4986
→ No significant relationship with TotalBill

Variable: DoctorName
Chi2: 350587.0304, p-value: 0.5552
→ No significant relationship with TotalBill

Variable: TreatmentType
Chi2: 2863.2094, p-value: 0.4743
→ No significant relationship with TotalBill

Variable: Medicine1
Chi2: 27663.8823, p-value: 0.4534
→ No significant relationship with TotalBill

Variable: Medicine2
Chi2: 27652.0842, p-value: 0.4733
→ No significant relationship with TotalBill


Variable: Medicine3
Chi2: 18929.1735, p-value: 0.4553
→ No significant relationship with TotalBill

Variable: Medicine4
Chi2: 10147.4854, p-value: 0.4244
→ No significant relationship with TotalBill
```

RESULTATS I IDENTIFICACIÓ D'INSIGHTS

Distribució de malalties en funció de l'edat

Els pacients més grans tenen una major incidència de malalties cròniques com la diabetis i la hipertensió, indicant que l'edat és un factor clau associat amb la prevalença d'aquestes patologies. Això subratlla la necessitat de prestar especial atenció a la població d'edat avançada per a la prevenció i el maneig adequat d'aquestes condicions.




En funció de l'edat, el nombre de pacients augmenta a mesura que incrementa el rang d'edat. Els pacients amb diabetis (48 casos) i hipertensió (44 casos) dins del rang de 81-100 anys són els que presenten un nombre més gran de casos. Tot seguit, es troben els pacients de la mateixa edat amb Covid-19, així com els pacients diabètics dins del rang de 66-80 anys.

Distribució de malalties en funció del gènere.

Pel que fa al gènere, no s'observa un patró generalitzat entre ell i la incidència de malalties. Tot i això, es constata que les pacients femenines presenten una incidència més elevada de Covid-19 en els tres tipus de tractament, mentre que la seva incidència és més baixa en els tres tipus de tractament per a visites relacionades amb la grip. Aquestes diferències suggereixen que alguns patògens poden afectar de manera desigual homes i dones, la qual cosa podria ser rellevant per al disseny de mesures preventives i tractaments diferenciats segons el gènere.


HEALTHCARE DATA ANALYSIS

Anàlisi de dades exploratòries i Processament de text no estructurat



Distribució temporal de malalties en funció del gènere

Els resultats indiquen una tendència general a la disminució de la incidència de les malalties analitzades el 2023, suggerint possibles efectes de les mesures sanitàries, la vacunació o canvis en la població de pacients. Això reflecteix una millora general en el control i la prevenció d'aquestes condicions respecte als anys anteriors.



En general, s'observa un descens marcat dels casos de Covid-19 des del 2021 en tots els gèneres. Tot i l'increment més o menys generalitzat de casos el 2022, es constata una disminució dels casos de les altres quatre malalties (diabetis, grip, hipertensió i asma) durant el 2023.

Top5 Medicaments habituals segons la prescripció mèdica dels pacients

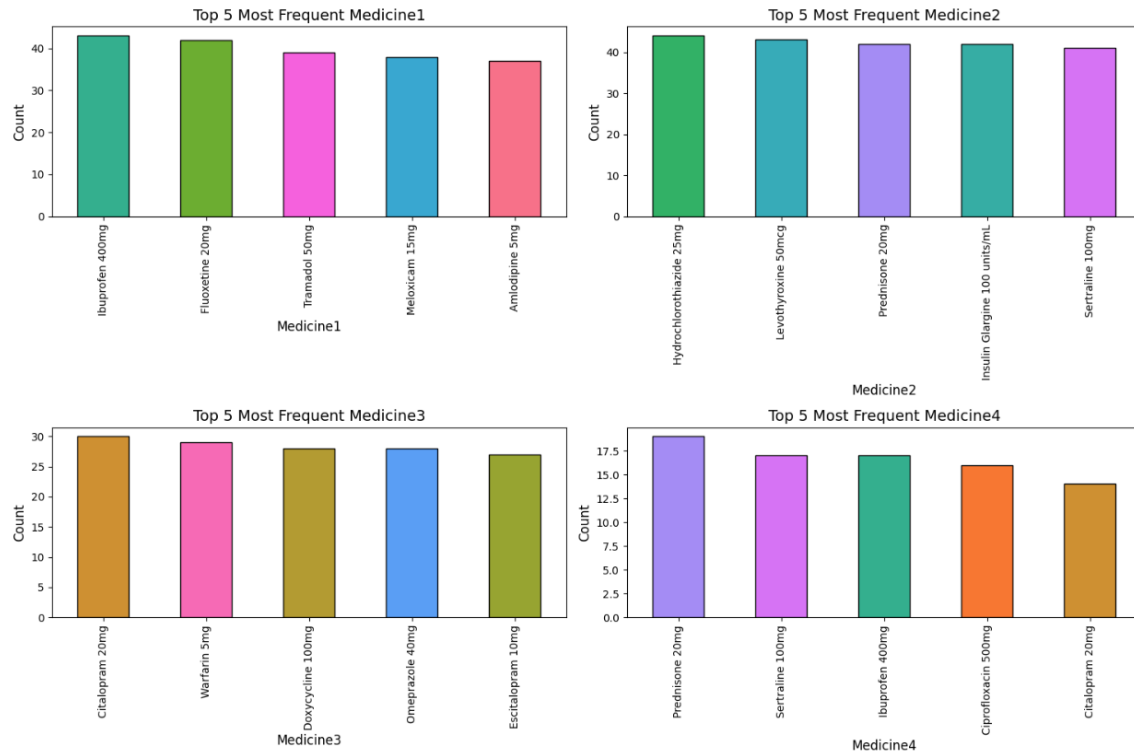
El medicament més prescrit al llarg dels anys és l'ibuprofèn 400 mg, que també apareix en quart lloc com a complement d'altres tractaments. Tot i això, el grup d'antidepressius és el més freqüent en general, ja que inclou la sertralina 100 mg, el citalopram 20 mg, l'escitalopram 10 mg i la fluoxetina 20 mg.

Així doncs, malgrat que l'ibuprofèn és el medicament individualment més prescrit, la major freqüència dels antidepressius indica que els tractaments relacionats amb la salut

HEALTHCARE DATA ANALYSIS


Anàlisi de dades exploratòries i Processament de text no estructurat

mental tenen un pes rellevant en la població de pacients, reflectint possiblement una demanda creixent d'aquest tipus de medicació.



Top5 Medicaments prescrits per anys

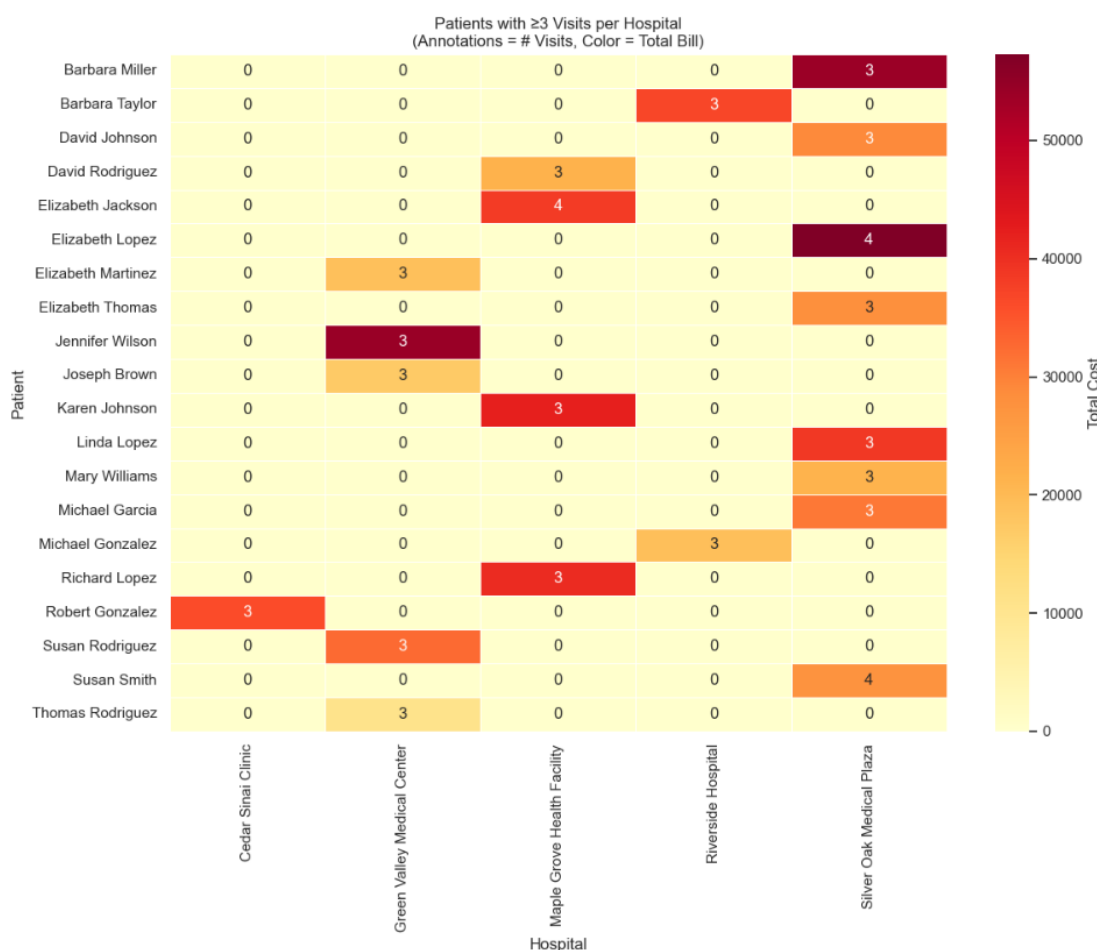
Quan s'analitza per anys, l'ibuprofèn 400 mg, un antiinflamatori no esteroïdal, va ser el medicament més prescrit el 2021. El 2022, el medicament més prescrit va ser la prednisolona 20 mg, un altre antiinflamatori però més potent. No és fins al 2023 que el citalopram 20 mg, un antidepressiu, apareix com el medicament més prescrit.



Els resultats mostren una evolució en les preferències de prescripció al llarg dels anys, passant dels antiinflamatoris el 2021 i 2022 als antidepressius el 2023. Això podria reflectir un canvi en les necessitats terapèutiques de la població, amb un augment de l'atenció a la salut mental en els darrers anys.

Anàlisi del pacients amb ≥ 3 visites per hospital

S'identifiquen 20 pacients que han realitzat tres visites o més per hospital. El **Silver Oak Medical Plaza** és l'hospital que concentra el nombre més gran de pacients reincidentes, mentre que el **Cedar Sinai Clinic** només ha registrat un pacient amb tres visites.




La distribució de pacients amb múltiples visites mostra una variabilitat significativa entre hospitals. Això suggereix que alguns centres, com el Silver Oak Medical Plaza, tenen una major recurrència de pacients, la qual cosa podria reflectir factors com la freqüència de visites programades, la complexitat dels casos o la preferència dels pacients per determinats hospitals.

Anàlisi de la reincidència: pacients amb ≥ 6 visites en ≥ 2 hospitals

S'identifiquen 9 pacients que han realitzat 6 visites o més en total en 2 o més hospitals. El nombre màxim de visites és de 7, i es registra en 4 hospitals diferents. El **Riverside Hospital** concentra el nombre més baix de pacients reincidentes, mentre que el **Cedar Sinai Clinic** presenta el nombre més alt de pacients que l'han visitat més d'una vegada durant els últims tres anys.

HEALTHCARE DATA ANALYSIS

Anàlisi de dades exploratòries i Processament de text no estructurat



Tot i que només un petit grup de pacients (9) acumula múltiples visites en diversos hospitals, la distribució mostra diferències entre centres. Això indica que alguns hospitals, com el **Cedar Sinai Clinic**, tenen més pacients recurrents, mentre que altres, com el **Riverside Hospital**, registren menys reincidències. Aquesta informació pot ser útil per analitzar patrons d'ús dels serveis de salut i optimitzar l'assignació de recursos i el seguiment dels pacients amb visites repetides.

DISCUSSIÓ

Aquest estudi analitza un conjunt de dades sintètiques del sistema de salut amb l'objectiu d'identificar les variables que afecten el cost dels pacients als hospitals, basant-se en diverses característiques clíniques i administratives. L'anàlisi de correlació de Spearman, adequada per a variables amb distribucions no normals, va mostrar que la relació entre la majoria de variables i els costos és pràcticament insignificant.

Les tècniques estadístiques aplicades, com el t-test i el Chi-quadrat (χ^2), van confirmar que moltes variables no presentaven una relació estadísticament significativa amb els costos. Només algunes variables, com l'edat i la malaltia (diagnosi), mostraven diferències significatives respecte al cost, ressaltant així la limitació de les variables disponibles per a una anàlisi precisa.

Malgrat aquestes limitacions, l'estudi segueix un enfocament metodològic robust, incloent una neteja exhaustiva de les dades, una anàlisi exploratòria (EDA) i la visualització de patrons. Això el converteix en un exercici acadèmic valuós.

Des d'una perspectiva pràctica, els resultats indiquen que les variables disponibles al conjunt de dades no són suficients per predir amb precisió els factors que influeixen en els costos hospitalaris. Les fortaleces de l'estudi resideixen en la seva metodologia completa i rigorosa, mentre que la principal limitació és la naturalesa sintètica de les dades, que no reflecteix la variabilitat i complexitat dels registres clínics reals.

CONCLUSIONS

L'estudi va seguir un procés metodològic complet que inclou la neteja i transformació de dades, la detecció d'outliers i l'anàlisi estadística. Els resultats indiquen que aquest procés va ser exitós, així com l'extracció d'informació bàsica de textos i l'anàlisi exploratòria (EDA). La qualitat del conjunt de dades es confirma com un factor clau per obtenir resultats significatius i fiables. A més, es va dur a terme una anàlisi detallada de les relacions entre variables, revelant alguns patrons que ajuden a comprendre com interactuen les diferents característiques entre si.

La naturalesa sintètica de les dades constitueix la principal limitació del projecte, ja que restringeix la capacitat d'obtenir resultats aplicables directament a entorns clínics reals. Algunes variables amb alta cardinalitat, com "DoctorName", "PatientName" o "RoomNumber", van ser considerades poc informatives per a l'anàlisi, ja que no aportaven agrupacions consistentes i complicaven la interpretació dels resultats.

Pel que fa als costos (TotalBill), es va identificar poca relació amb la majoria de variables. Només l'edat i la diagnosi van mostrar diferències estadísticament rellevants respecte als costos.

Els pacients d'edat avançada amb malalties cròniques concentren la majoria de visites hospitalàries. En general, s'observa un descens global de visites per totes les malalties el 2023, així com un descens continu des del 2021 en pacients afectats de Covid-19. També s'ha detectat un creixement constant en les prescripcions de medicació per a salut mental, amb una variació dels pacients reincidentes segons l'hospital.

En conclusió, tot i les limitacions derivades de la naturalesa sintètica de les dades, l'estudi proporciona una base sòlida per a futures investigacions sobre la predicció de costos hospitalaris i destaca la importància de disposar de dades de qualitat per obtenir resultats robustos i aplicables.

TREBALL FUTUR

Per a treballs futurs, es proposa aplicar models de Machine Learning per a predir tant el TotalBill com el RecoveryRating dels pacients, amb l'objectiu de millorar la comprensió dels factors que afecten els costos i la recuperació.

A més, es podrien utilitzar tècniques més avançades de processament de llenguatge natural (NLP) per analitzar de manera més precisa les prescripcions i detectar patrons rellevants en la medicació.

També es considera incloure variables altres addicionals com:

- comorbiditats, malalties o trastorns addicionals que una persona té al mateix temps que la malaltia principal, com per exemple, diabetis o hipertensió.
- resultats de laboratori (glucosa, creatinina, entre d'altres), amb la finalitat d'enriquir el model i augmentar la seva capacitat predictiva.

Finalment, es planeja validar els resultats en conjunts de dades reals del sistema de salut, per assegurar que les conclusions siguin aplicables i rellevants en entorns clínics reals.

BIBLIOGRAFIA

Raghupathi, W., & Raghupathi, V. (2014). Big data analytics in healthcare: Promise and potential. *Health Information Science and Systems*, 2(3).

Wang, Y., Kung, L., & Byrd, T. A. (2018). Big data analytics: Understanding its capabilities and potential benefits for healthcare organizations. *Technological Forecasting and Social Change*, 126, 3–13.

Hoffman, M., & Gelman, A. (2014). *Bayesian data analysis for healthcare and epidemiology*. CRC Press.

Marques, G., et al. (2019). *Data analytics in healthcare: Methods, applications, and tools*. Springer.

Ristevski, B., & Chen, M. (2018). Big data analytics in medicine and healthcare. *Journal of Integrative Bioinformatics*, 15(3), 1–17.

Bates, D. W., & Wright, A. (2009). Evaluating the impact of health information technology on healthcare quality and safety. *BMJ*, 338, b235.

Murdoch, T. B., & Detsky, A. S. (2013). The inevitable application of big data to health care. *JAMA*, 309(13), 1351–1352.

Kaggle. (n.d.). *Healthcare datasets*. <https://www.kaggle.com/datasets?search=healthcare>

Centers for Disease Control and Prevention. (n.d.). *Data & statistics*. <https://www.cdc.gov/datastatistics/index.html>

World Health Organization. (n.d.). *Global Health Observatory*. <https://www.who.int/data/gho>